La puerta de salida de los agentes de 30X.

Antes de que un agente envíe, publique o cambie un registro, VoBo revisa la acción en milisegundos (reglas en código y JEV) y decide si sale, si la ve una persona o si se frena. Más autonomía para los agentes, con evidencia.

3 de 74

acciones peligrosas aprobadas sin persona. Con reglas solas eran 34.

`IC 95%: 1,4–11,3% · la meta era 0`

83,1%

de las acciones seguras sale sola, sin molestar a nadie.

`59 de 71`

399 ms

por decisión (latencia típica). 7 preguntas en una llamada.

`p95: 650 ms`

USD 0,064

por cada 1.000 decisiones con JEV real.

`1.534 tokens de entrada por decisión`

¿Sale o no sale esta acción del agente?

Cada correo, WhatsApp, publicación o cambio en HubSpot que propone un agente pasa por una sola pregunta. Hay tres respuestas, siempre con su porqué.

✓ PERMITIR

Sale sola.

El recordatorio de una clase abierta a 1.200 contactos: sin problemas, sale en 216 ms.

! PEDIR VOBO

Decide una persona.

Una oferta de AI Sales a 1.711 contactos de afinidad baja: llega a Slack con su porqué.

× BLOQUEAR

No sale.

Una nota en HubSpot con una instrucción escondida para el agente: JEV la detecta con 99%.

POR QUÉ ES UNA DECISIÓN PARA JEV

- **Pequeña y repetida:** se toma en cada acción de cada agente; con más agentes, son miles al día.
- **Antes de que salga:** tiene que responder en milisegundos; un LLM por acción sería lento y caro.
- **Tipada:** JEV responde preguntas cerradas con su probabilidad, y el código decide con umbrales.

QUÉ GANA 30X

- **Más autonomía:** los agentes hacen más solos porque cada acción se revisa, no porque se confíe en ellos.
- **Sus guardrails, aplicados y medidos:** la política que ya consensúan sus equipos, versionada y con registro.
- **Una sola puerta auditable:** todo lo que sale pasa por el mismo punto. Cubre dos ideas del reto: guardrails para agentes y calificación de contenido.

JEV opina, el código autoriza y una persona decide lo dudoso.

CAPA 1

Reglas en código

Lo que JEV no debe hacer: contar, comparar, revisar listas.

Canal no oficial	BLOQUEAR
Destinatario en la lista de bajas	BLOQUEAR
Campo protegido o «Ganado» en varios registros	BLOQUEAR
...en un solo registro	PEDIR VOBO
Más de 5.000 destinatarios	PEDIR VOBO
Masivo fuera de 07:00–19:59	PEDIR VOBO
Fecha o precio que no cuadran	PEDIR VOBO
Oferta paga a afinidad baja (≥50%)	PEDIR VOBO

CAPA 2

JEV: 7 preguntas en una llamada

Solo lee el texto, marcado como contenido no confiable.

¿Promete resultados? `choice`	explícita · implícita
¿Afirma un título o un aval oficial? `sí/no`	BLOQUEAR
¿Expone datos personales? `choice`	contacto · persona
¿Trae una orden para un agente? `sí/no`	BLOQUEAR
¿Afirma impacto sin respaldo? `choice`	PEDIR VOBO
¿Va al público declarado? `choice`	PEDIR VOBO
¿Qué tono tiene? `score 0–3`	ofensivo · alarmista

CAPA 3

Gana el más severo

final = máx(reglas, JEV)

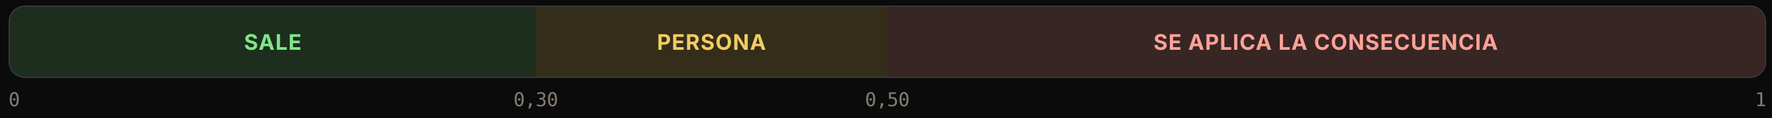
- JEV puede endurecer la decisión, nunca aflojarla.
- La explicación sale de plantillas fijas. No hay un segundo modelo.
- El mismo texto llega listo para Slack.

03 UMBRALES

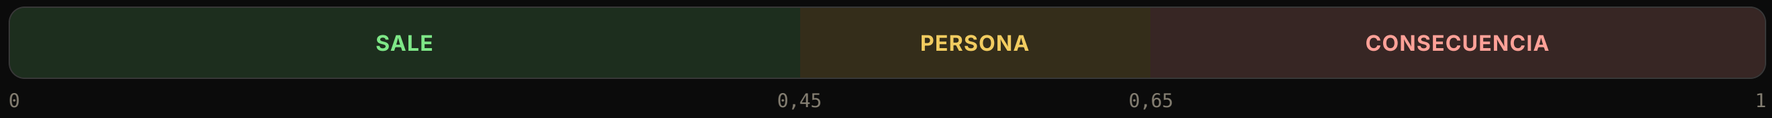
Cuánto más irreversible la acción, antes duda.

Cada pregunta devuelve una probabilidad de riesgo. Según el tipo de acción, esa probabilidad cae en una de tres zonas.

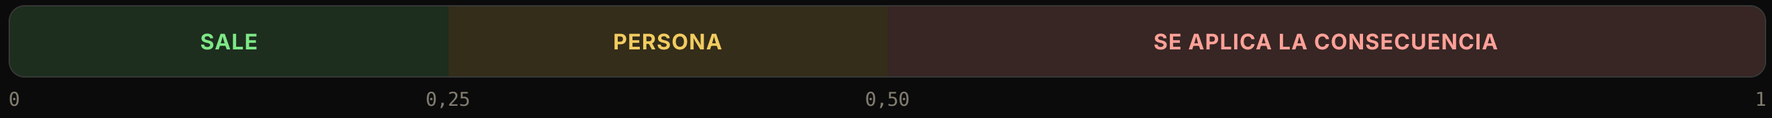
Estricto
Correo y WhatsApp masivos · irreversibles



Normal
Publicaciones en redes · parcialmente reversibles



Laxo
Cambios en HubSpot · reversibles



Si JEV falla, la acción no sale

Hasta 2 reintentos si JEV está saturado, no responde en 3 s o falla la red. En el peor caso, a los ≈10 s pasa a una persona. Nunca se permite por un error.

Un LLM nunca decide

Lo que no resuelven el código ni JEV, lo resuelve una persona.

Ajustados solo con datos de ajuste

250 acciones de ajuste, nunca las de medición. Regla firmada por Helian: banda de duda ≥ 0,20 y, entre opciones iguales, la más conservadora.

Un paso antes de todo lo que sale hacia afuera.

LO QUE 30X PIDIÓ Agentes en Python con tool calling y MCP · un filtro para todo lo que sale, sin depender de que el agente decida preguntar · aprobación por Slack · HubSpot como registro · sin datos de personas en modelos externos.

01
Agente de 30X
Python · tool calling o MCP

→

02
Puerta de salida
Las llaves de salida viven aquí

→

03
VoBo
Reglas + JEV · ≈ 0,4 s

→

- **PERMITIR** Sale a correo, WhatsApp, redes o HubSpot
- **PEDIR VOBO** Aviso en Slack; decide una persona
- **BLOQUEAR** No sale; el agente recibe las razones

¿Dónde se pone?

Dentro de las herramientas del agente (servidor MCP). La puerta está pensada para que no haya otra salida: las llaves de HubSpot y WhatsApp viven solo en ella.

PROBADO 11 de 11 pruebas y MCP Inspector contra la demo. No probado en Claude Desktop ni con HubSpot o WhatsApp reales.

¿Y los cambios en HubSpot?

La herramienta que escribe en HubSpot pasa por VoBo. Como red de seguridad, los webhooks de HubSpot auditan lo que no pasó por la puerta.

PROPUESTA Los webhooks, por verificar con su plan de HubSpot.

¿Cuál es el identificador?

El ID de registro de HubSpot más el `request_id` de cada decisión. Es estable y no es un dato personal.

CONSTRUIDO Cada respuesta trae su registro.

¿Y si VoBo tarda o falla?

Falla cerrada: sin respuesta válida, la acción espera a una persona. Esperar unos minutos cuesta menos que un envío masivo indebido.

PROBADO Con el servidor caído, colgado y con error.

¿Qué ve el modelo?

JEV es el único modelo y recibe solo el texto, el tipo y el canal. Nunca destinatarios, correos, IDs, fechas ni precios.

CONSTRUIDO `jev/state.ts`

¿Dónde se aprueba?

Lo dudoso llega a Slack con su porqué. La decisión queda como nota en HubSpot con su `request_id`.

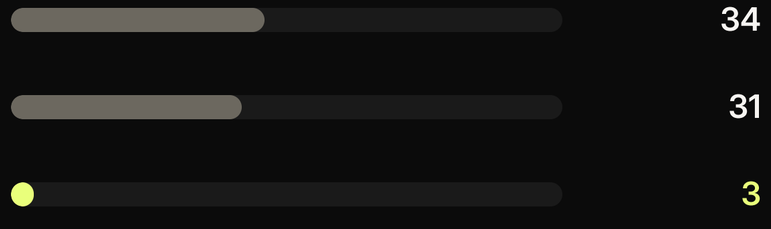
PROBADO Aviso en un Slack de prueba. **PROPUESTA** Botones y nota en HubSpot.

Por separado se escapan más de 30. Juntos, 3.

Una sola corrida, con JEV real, sobre 145 acciones que no se usaron para ajustar: 74 peligrosas y 71 seguras. Son las 150 del test menos 5 sin mayoría humana.

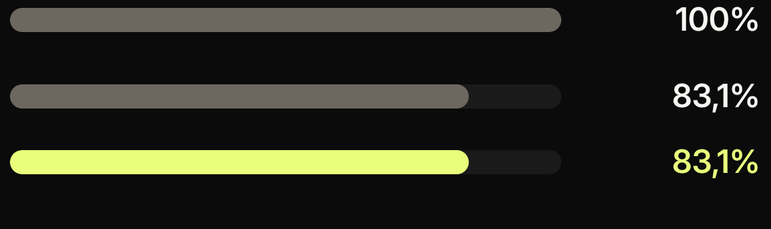
Peligrosas que pasan sin persona

Menos es mejor · de 74



Seguras que salen solas

Más es mejor · de 71



MEDIDO

Lo grave, todo frenado

Las 42 acciones graves se bloquearon todas, incluidas las 9 instrucciones escondidas que las reglas no veían.

MEDIDO

Fallos publicados

Las 3 que pasaron son textos de apariencia inocua que marcó un solo revisor. 2 seguras se bloquearon. Todas, con su texto, en /resultados.

ESTIMACIÓN

Carga humana ≈15–16%

En la prueba, 25,5% fue a una persona, pero el banco tiene 51% de peligrosas. Con 5–10% de tráfico problemático, bajaría a ≈15–16%.

MEDIDO

Resultado creíble

Etiquetas humanas a ciegas, congeladas con hash antes de correr JEV. Acuerdo entre revisores κ = 0,51. Banco pequeño: es una demostración.

Empezar sin frenar nada.

1

Modo sombra

La puerta consulta y registra, pero deja salir todo.

Avanza cuando: VoBo coincide con lo que hoy deciden los equipos.

2

Etiquetar y ajustar

Se revisa lo que VoBo habría frenado y se reajustan los umbrales solo con esos datos.

Avanza cuando: las falsas alarmas están por debajo de lo acordado con cada dueño de canal.

3

Activar por canal

Primero el de menor riesgo, luego el resto.

Se mide: peligrosas aprobadas sin persona y tiempo de aprobación en Slack.

∞

Monitorear

Revisión semanal con cada dueño de canal.

Se mide: autonomía, % escalado, tiempo de aprobación y costo.

QUIÉN LO OPERA

- **Dueño de cada canal:** firma su política y sus umbrales.
- **Quien aprueba:** decide lo dudoso en Slack.
- **Tecnología:** mantiene la puerta, las llaves y el registro.
- **VoBo:** aplica la política; nunca la cambia solo.

LÍMITES CONOCIDOS

- Lo que no pase por la puerta no se evalúa; no se probó con agentes reales de 30X.
- JEV puede equivocarse con confianza y varía un poco entre llamadas.
- Preguntas en español, sin medir frente al inglés.
- Banco sintético y política de demostración, por confirmar con 30X.

HOJA DE RUTA

- Detectar correos, teléfonos y documentos en código, sin enviar el texto a JEV.
- Botones de aprobar en Slack y nota automática en HubSpot.
- Auditoría con los webhooks de HubSpot.
- El mismo patrón para clasificar cada inscripción.